

面向动态开放未知场景的集群规划：大模型与形式逻辑融合驱动方法

¹卓安¹, 张硕¹, 国萌¹, 李忠奎^{1*}

(1. 北京大学 先进制造与机器人学院, 北京 100871)

摘要：面向动态开放未知场景下异构机器人集群任务规划中自然语言意图难以可靠转化、任务与资源状态在线变化、规划结果缺乏形式化校核等问题，提出一种大模型与形式逻辑融合驱动的集群规划方法。该方法以动态环境特征、任务集合、资源集合和任务依赖关系为基础，采用线性时序逻辑与任务自动机描述任务规范，结合检索增强生成和多阶段大模型推理生成候选子任务图，并通过滚动时域子任务分配实现任务到异构机器人个体或团队的映射。针对新任务类型/实例、新资源类型/实例和机器人故障等在线变化，设计事件触发自适应机制，仅激活必要规划模块进行局部更新；同时引入低负担人-群协同机制，在关键节点进行人工确认与修正。仿真和实物实验表明，所提方法能够提升动态开放未知场景下任务规划的成功率、一致性和在线适应能力，并降低操作员持续干预负担。

关键词：异构机器人集群；动态开放未知场景；大模型；线性时序逻辑；事件触发重规划；人-群协同

中图分类号：TP242.6

文献标志码：A

文章编号：

Melding LLM and temporal logic for reliable human-swarm collaboration in complex scenarios

ZHUO An¹, ZHANG Shuo¹, GUO Meng¹, LI Zhongkui^{1*}

(1. School of Advanced Manufacturing and Robotics, Peking University, Beijing 100871, China)

Abstract: A swarm planning method driven by large language models and formal logic is proposed for heterogeneous robots in dynamic, open, and unknown environments. The method models dynamic environmental features, tasks, resources, and task dependencies, represents task specifications with linear temporal logic and task automata, and generates candidate subtask graphs through retrieval-augmented generation and multi-stage reasoning. A rolling-horizon allocation module assigns executable subtasks to suitable robots or teams. Event-triggered adaptation updates only necessary modules under new task types or instances, new resource types or instances, and robot failures, while low-burden human-swarm interaction introduces human confirmation at critical stages. Simulations and hardware experiments verify the planning reliability, adaptability, and reduced operator workload.

Keywords: heterogeneous robot swarm; dynamic, open, and unknown environment; large language model; linear temporal logic; event-triggered replanning; human-swarm collaboration

Citation ZHUO An, ZHANG Shuo, GUO Meng, LI Zhong-kui. Melding LLM and temporal logic for reliable human-swarm collaboration in complex scenarios [J].

无人集群在应急处置、灾害救援、危险区域巡检和工业运维等场景中，常需要根据人类指挥员给出的高层任务意图，在未知环境中完成多类型任务。与封闭、静态场景不同，开放环境中的任务目标、资源位置、环境语义和机器人状态会随执行过程持续变化。此时，集群规划系统不仅要回答“由哪些机器人执行哪些任务”，还需要在任务持续出现、资源逐步发现和平台状态变化的条件下，保持任务分解、任务排序和协同分配结果的可执行性。

现有多机器人任务规划方法通常依赖较完整的先验任务集合、资源集合和约束描述。在动态开放场景中，这一假设难以满足：任务实例和资源实例可能在执行过程中才被感知和识别；任务之间又存在先后、同步或资源依赖关系，部分任务还需要多个具备互补能力的机器人协同完成。若规划系统仅在初始时刻生成固定方案，后续新任务、新资源或

机器人故障均可能破坏原有计划；若每次状态变化都触发全局重规划，又会带来较高计算负担，并影响长时程任务的连续执行。

近年来，大语言模型在自然语言理解、任务语义解析和开放知识推理方面表现出较强能力，为高层意图到机器人任务方案的转换提供了新的技术路径。然而，直接依赖大模型生成集群任务计划仍存在局限：任务序列可能遗漏时序关系，子任务可能不满足资源条件或机器人能力约束，规划结果也难以直接进行形式化验证。与之相对，线性时序逻辑和任务自动机能够对任务顺序、事件响应和可满足性进行严格描述，但通常需要较明确的任务规范和环境先验，难以单独应对开放场景中持续出现的新任务和新资源。

针对上述问题，本文提出一种面向动态开放未知场景的异构机器人集群任务规划方法，将大模型

¹ 收稿日期：2026-06-30

基金项目：国家自然科学基金资助项目（U2241214, T2121002, 62373008）

第一作者：卓安（2002—），男，湖南常德人，博士研究生，E-mail: zhuan@stu.pku.edu.cn;

* 通信作者：李忠奎（1984—），男，河南商丘人，教授，博士，博士生导师，E-mail: zhongkui.li@pku.edu.cn;

推理与形式逻辑约束纳入统一的神经符号规划框架。本文主要工作包括：给出异构机器人、动态环境特征、任务集合、资源集合、任务依赖关系和子任务图的统一描述；提出大模型与形式逻辑融合的集群规划流程，通过 LTL、任务自动机、检索增强生成、多阶段推理和滚动时域优化完成子任务分配；结合事件触发在线自适应与低负担人-群协同机制，验证方法在动态任务处理、资源变化适应和异构机器人协同执行中的可用性。

1 问题描述

1.1 异构集群与动态环境特征

考虑一个由异构机器人集合 $\mathcal{R}$ 构成的多机器人系统，其运行于动态三维工作空间 $\mathcal{W} \subset \mathbb{R}^3$ 中。设系统包含 $K > 0$ 类不同能力的机器人，第 k 类机器人集合记为 $\mathcal{R}_k$ ，其数量为 $N_k = |\mathcal{R}_k|$ ，并满足：

$$\mathcal{R} = \bigcup_{k=1}^K \mathcal{R}_k, \quad \mathcal{R}_k \cap \mathcal{R}_{k'} = \emptyset, \quad \forall k \neq k'.$$

对于任意机器人 $i \in \mathcal{R}$ ，记其状态为 x_i ，位置为 $p_i \in \mathcal{W}$ ，能力集合为 S_i 。由于不同类型机器人能够承担的任务类型并不相同，后续任务分配不能仅依据机器人数量进行安排，还需要判断机器人团队是否具备子任务所需的综合能力。为此，定义任意机器人子集 $\mathcal{R}' \subseteq \mathcal{R}$ 的联合能力集合为：

$$S(\mathcal{R}') = \bigcup_{i \in \mathcal{R}'} S_i.$$

动态开放场景中的任务对象和可用资源并非离线完整给定。系统在执行过程中持续感知工作空间 $\mathcal{W}$ ，并逐步发现与任务执行相关的环境特征。记时刻 t 已被系统发现的特征集合为 $\mathcal{F}(t)$ 。这些特征可能对应待执行任务，也可能对应任务执行所需资源，因此规划过程需要随环境信息更新而调整。

1.2 任务、资源与依赖关系建模

在动态环境特征基础上，记时刻 t 已识别出的任务集合与资源集合分别为：

$$\mathcal{T}(t) \subseteq \mathcal{F}(t), \quad \mathcal{B}(t) \subseteq \mathcal{F}(t).$$

其中， $\mathcal{T}(t)$ 表示当前已知任务实例集合， $\mathcal{B}(t)$ 表示当前已知资源集合。设系统可处理的任务类型集合为 $\mathcal{M}$ 。对于任意任务实例 $\tau \in \mathcal{T}(t)$ ，其对应任务类型记为 $m(\tau) \in \mathcal{M}$ 。不同任务之间可能存在先后或协同约束，记时刻 t 的任务间依赖关系为：

$$\mathcal{D}(t) \subseteq \mathcal{T}(t) \times \mathcal{T}(t).$$

对于任意 $(\tau_i, \tau_j) \in \mathcal{D}(t)$ ，表示任务 τ_j 的执行受到任务 τ_i 的约束。环境中生成或识别出的任务通常不能被机器人直接执行，需要进一步转化为可执行的子任务序列。对于任意任务 τ ，记其对应的子任务集合和子任务关系为：

$$\tau \triangleq \{s_\tau^1, s_\tau^2, \dots, s_\tau^{L_\tau}\}, \quad G_\tau = (S_\tau, \mathcal{E}_\tau).$$

其中， S_τ 为子任务节点集合， $\mathcal{E}_\tau$ 用于描述子任务之间的先后关系与协同关系。对于任意子任务 s ，记其能力需求为 $Req(s)$ 。若机器人集合 $\mathcal{R}_s(t) \subseteq \mathcal{R}$ 被分配用于执行该子任务，则必须满足：

$$Req(s) \subseteq S(\mathcal{R}_s(t)).$$

1.3 问题表述

在动态开放未知场景中，机器人集群面对的任务集合、资源集合和环境特征会随执行过程持续更新。在线任务规划策略 Π 的输入由机器人状态、已发现环境特征、任务集合、资源集合和历史执行结果等共同构成；其输出为任务识别、任务分解、子任务排序、机器人团队分配和相应执行安排。给定有限任务执行时域 $[0, T]$ ，定义任务完成指示变量：

$$z_\tau(T) = \begin{cases} 1, & \tau \text{ is completed in } [0, T], \\ 0, & \text{otherwise.} \end{cases}$$

本文目标是在满足任务间依赖关系、子任务执行顺序和能力约束的前提下，使异构机器人系统在有限时间内完成尽可能多的任务：

$$\max_{\Pi} \sum_{\tau \in \mathcal{T}(T)} z_\tau(T).$$

该目标需满足任务依赖、子任务先后关系和执行可行性约束：若 $(\tau_i, \tau_j) \in \mathcal{D}(t)$ ，则任务 τ_j 不得早于任务 τ_i 完成前启动；若 $(s, s') \in \mathcal{E}_\tau$ ，则子任务 s' 不得早于 s 完成前启动；每个被调度子任务均应由非空机器人集合执行，并在有限时域内完成。

2 大模型与形式逻辑融合规划方法

2.1 总体框架

如图 1 所示，本文构建的大模型与形式逻辑融合规划框架由环境感知与特征识别、任务推理、子任务生成、子任务分配和人机交互五个模块组成。环境感知模块将机器人机载或载体传感器获取的观测信息转化为任务、资源和事件描述，并动态更新场景语义；任务推理模块结合线性时序逻辑公式与




图 1 大模型与形式逻辑融合的集群规划框架

Fig.1 - Framework of LLM-and-temporal-logic-driven swarm planning

任务自动机，对任务间的时序关系、触发条件和执行约束进行形式化刻画；子任务生成模块进一步利用检索增强生成和多阶段大模型推理，将高层任务目标分解为满足逻辑约束的候选子任务图。

在此基础上，子任务分配模块根据机器人能力、任务依赖、资源状态和执行风险，滚动生成当前可执行的机器人团队分配与调度方案。人机交互模块则在任务识别、子任务确认、分配调整和路径修正等关键节点引入操作员反馈，使规划过程在保持自动化执行的同时具备人工校核能力。由此，本文方法并非一次性生成静态任务计划，而是在环境信息持续更新、形式化约束校核和人群反馈闭环中实现动态规划与在线调整。

2.2 基于形式逻辑的任务推理

动态开放场景中的任务需求不仅包含预先给定的执行目标，还可能包含由环境事件触发的响应要求。记时刻 t 的活动任务规范集合为 $\mathcal{Q}(t)$ 。对于任意任务规范 $q \in \mathcal{Q}(t)$ ，记其关联任务实例集合为 $T_q(t) \subseteq \mathcal{T}(t)$ 。设可观测事件集合为 V_q ，对于任意事件 $e \in V_q$ ，用命题公式 ψ_e 表示事件发生，

用 φ_e^{res} 表示事件发生后系统应满足的响应要求，则任务规范可表示为：

$$\varphi_q = \varphi_q^{\text{nom}} \wedge \bigwedge_{e \in V_q} (\psi_e \rightarrow F\varphi_e^{\text{res}}).$$

其中， φ_q^{nom} 表示任务常规要求， φ_e^{res} 表示事件触发后的响应要求，二者均采用 sc-LTL 描述。为便于后续搜索与验证，将每个任务规范 φ_q 等价转化为非确定性 Büchi 自动机：

$$\mathcal{A}_q = (\mathcal{Q}_q, \mathcal{Q}_q^0, 2^{AP_q}, \delta_q, F_q).$$

其中， $\mathcal{Q}_q$ 为状态集合， $\mathcal{Q}_q^0$ 为初始状态集合， AP_q 为原子命题集合， δ_q 为状态转移函数， F_q 为接受状态集合。若某一任务执行轨迹能够诱导自动机从初始状态集合到达接受状态集合，则说明该轨迹满足对应任务规范。

在得到形式化任务规范后，还需将当前已知任务实例分配给不同机器人组。设系统被划分为 H 个协作机器人组，分别记为 $\mathcal{R}^{(1)}, \mathcal{R}^{(2)}, \dots, \mathcal{R}^{(H)}$ ，第 h 个机器人组的局部任务序列记为 π_h 。本文采用多自动机引导的树搜索方法，在不显式构造全

局同步积模型条件下，同步完成任务规范推理与机器人组分配。搜索树记为：

$$Y(t) = (\mathcal{N}(t), \mathcal{L}(t)).$$

搜索过程按照“选择—扩展—剪枝—终止”的步骤进行。选择阶段依据各机器人组预计完成时间、局部任务序列代价和自动机到接受状态的距离估计综合评价节点；扩展阶段仅将能够推动自动机状态前进且机器人组能力满足要求的任务纳入候选；剪枝阶段采用性能向量的非支配判定，保留非支配前沿；终止阶段在能够使各任务自动机到达接受状态的完整分配节点中选择当前最优节点。

2.3 检索增强的子任务生成

经过任务推理后，系统获得任务实例到机器人组的高层分配结果以及任务间时序依赖关系，但这些结果仍不能直接用于机器人执行。对于分配给机器人组 $\mathcal{R}^{(h)}$ 的任意任务 τ ，构造其上下文输入为：

$$\mathcal{C}_\tau^{(h)}(t) = (K(t), S(\mathcal{R}^{(h)}), I_\tau^{obs}(t), \mathcal{D}(t)).$$

其中， $K(t)$ 表示当前可用知识库信息，包括地图、符号规则与经验知识等； $S(\mathcal{R}^{(h)})$ 表示机器人组联合能力； $I_\tau^{obs}(t)$ 表示与任务相关的结构化多模态观测； $\mathcal{D}(t)$ 提供任务层面的时序约束背景。

子任务生成采用检索增强生成与多阶段推理相结合的方式。首先，从任务方案库中检索与当前上下文最相关的历史子任务模式，作为生成过程的外部先验；随后通过多阶段推理逐步生成可执行子任务结构：MS-p1 分析任务语义、环境状态与领域知识，识别任务目标、关键资源及潜在约束；MS-p2 处理资源缺失、协同执行以及特殊时序要求；MS-p3 在前两阶段基础上生成满足约束的子任务序列及其依赖关系。

对于任务 τ ，大模型最终输出的不是单一子任务序列，而是一组候选的分层有向无环图：

$$\mathfrak{G}_\tau = \{G_\tau^{(1)}, G_\tau^{(2)}, \dots, G_\tau^{(M_\tau)}\},$$

$$G_\tau^{(m)} = (\mathcal{S}_\tau^{(m)}, \mathcal{E}_\tau^{(m)}, \ell_\tau^{(m)}).$$

其中， $\mathcal{S}_\tau^{(m)}$ 为子任务节点集合， $\mathcal{E}_\tau^{(m)}$ 为子任务之间的依赖关系， $\ell_\tau^{(m)}$ 为节点或边的标签信息，用于描述资源需求、执行属性、优先级以及是否需要多机器人协同等内容。若某一子任务 s 的资源需求集合 $Res(s)$ 不包含于当前资源集合 $\mathcal{B}(t)$ ，即：

$$Res(s) \not\subseteq \mathcal{B}(t),$$

则说明执行该子任务所需资源尚未被系统掌握，此时系统引入探索类子任务，用于搜索缺失资源的可能位置。

2.4 滚动时域子任务分配

在得到每个任务对应的候选子任务图之后，需要从中选择具体执行方案，并将其中各子任务分配给机器人组内的具体机器人个体或协作团队。设机器人组 $\mathcal{R}^{(h)}$ 在时刻 t 所需处理的子任务集合为 $\mathcal{T}^{(h)}(t)$ 。对于任意 $\tau \in \mathcal{T}^{(h)}(t)$ ，从其候选子任务图集合 $\mathfrak{G}_\tau$ 中选取一个候选图；由所有已选候选图共同诱导得到当前滚动时域内的可执行子任务集合，记为 $\mathcal{S}_h^{eli}(t)$ 。

对于任意子任务 $s \in \mathcal{S}_h^{eli}(t)$ ，记其成功概率为 p_s ，预计持续时间为 d_s ，并给定机器人组可接受的不确定性预算 $\varepsilon_h > 0$ 。引入二进制变量 y_{is} 表示机器人 $i \in \mathcal{R}^{(h)}$ 是否参与执行子任务 s ，引入连续变量 t_s^{start} 表示子任务 s 的开始时间。当前滚动时域内的子任务分配目标为：

$$\min T_h^{max}.$$

该优化目标表示最小化当前滚动时域内的局部完工时间。主要约束包括：

$$\sum_{i \in \mathcal{R}^{(h)}} y_{is} \geq 1, \quad Req(s) \subseteq S(\mathcal{R}_s(t)),$$

$$\mathcal{R}_s(t) = \{i \in \mathcal{R}^{(h)} \mid y_{is} = 1\}.$$

$$t_s^{start} \geq t_{s'}^{start} + d_{s'}, \quad \forall (s, s') \in \mathcal{E}_\tau.$$

$$\sum_{s \in \mathcal{S}_h^{eli}(t)} (1 - p_s) \sum_{i \in \mathcal{R}^{(h)}} y_{is} \leq \varepsilon_h.$$

由于同一高层任务通常对应多个候选子任务图，本文对不同候选子任务图组合分别构造当前可执行子任务集合及其依赖关系，并求解相应分配问题，从所有可行解中选取目标函数值最优者作为当前执行方案。实际执行过程中，系统仅将当前阶段满足前置条件且已通过能力约束验证的子任务下发给机器人团队，并在环境观测与资源状态变化时重新求解。

2.5 在线自适应与低负担人-群协同

开放环境中的任务执行过程通常伴随着新任务出现、新资源发现、资源状态变化和机器人故障等在线事件。若每次变化均触发全局重规划，不仅会增加计算开销，也容易破坏正在执行任务的连续性。




图 2 事件触发的在线自适应机制

Fig.2 - Event-triggered online adaptation mechanism

为此，本文设计事件触发的在线自适应机制，使系统根据事件类型选择性更新任务资源集合、子任务图或机器人状态，而非重新生成完整规划结果。

如图 2 所示，不同类型变化仅激活与其相关的规划模块。当出现新任务类型时，系统更新任务规范、子任务生成规则和任务推理模块；当出现新任务实例时，系统将其加入当前任务集合，并在已有任务依赖关系基础上更新子任务图；当发现新资源类型或新资源实例时，系统更新资源集合及其可用性，并重新评估相关子任务的执行条件；当机器人发生故障时，系统更新机器人可用状态和能力集合，并仅对受影响的子任务分配结果进行局部调整。通过这种方式，规划过程能够在保持原有任务执行结构的同时，对动态变化进行快速响应。

为降低操作员持续监控负担，本文进一步引入低负担人-群协同机制。操作员不需要持续参与每一步规划计算，而仅在任务识别不确定、子任务生成存在歧义、分配结果需要确认或路径执行存在风险时进行确认与修正。该机制将人工参与压缩到少量关键节点，使系统在保持自动化执行效率的同时，具备必要的人工校核能力和任务安全性。

除人工交互外，系统还需要在执行过程中持续监测当前行为是否仍与任务规范保持一致。对于任

意任务规范，其执行过程可由已完成任务序列不断映射到对应自动机上。若记当前新完成任务对应的原子命题标签为 $L(\tau)$ ，则自动机可达状态集合可更新为：

$$\mathcal{Z}_q^+ = \delta_q(\mathcal{Z}_q, L(\tau)).$$

进一步定义当前自动机到接受状态集合的最短距离为：

$$d_q = \min_{z \in \mathcal{Z}_q} d(z, F_q).$$

若 $d_q = \infty$ ，则说明当前执行轨迹已无法继续满足对应任务规范，系统触发人工确认或在线重规划。若任务约束图表明任务 τ_i 必须先于任务 τ_j 执行，则应满足：

$$t_{\tau_i}^{fin} \leq t_{\tau_j}^{start}.$$

若两个任务需要协同同步启动，则应满足：

$$t_{\tau_i}^{start} = t_{\tau_j}^{start}.$$

3 实验验证

3.1 实验设置

为验证所提方法在动态开放场景中的任务规划能力，本文构建了化工厂搜救与应急处置实验场景，任务类型包括火灾扑救、伤员救援、设备维护和泄漏处置等。任务实例由环境感知过程动态触发，并可能伴随新资源发现、资源位置更新和机器人状态变化。实物实验平台与场景布置如图 3 所示，系统由无人直升机、无人轮式车、履带车、四足机器人以及操作员终端组成，用于验证异构机器人集群在开放任务环境中的协同执行能力。



图 3 实物实验平台与系统部署

Fig.3 - Hardware experimental platform and system deployment

在仿真实验中，本文设置简单、中等和困难三类场景，环境特征数量分别为 100、200 和 400 个，每个难度等级重复进行 10 次独立试验。机器人集群由 40 台异构平台组成，包括无人直升机、无人机、无人轮式车、履带车和轮式车等。不同难度场景用于评估方法在任务密度增加、资源发现延迟和执行状态动态变化条件下的规划稳定性与可扩展性。

系统架构




图 4 云-边-端三层系统架构

Fig.4 - Cloud-edge-device three-layer system architecture

系统采用云-边-端三层架构实现任务规划与机器人执行的闭环协同，如图 4 所示。云端主要负责基于 LTL 的任务理解、任务规范管理和高层任务调度；边缘层负责环境分析、子任务生成、子任务分配和多机器人协同协调；端侧机器人负责多模态感知、局部通信、动作执行和运动规划。各层模块通过 ROS 通信桥接和 TCP/UDP 协议完成数据传输与指令下发，使高层任务推理结果能够映射到具体机器人平台的执行动作。

实验评价指标包括任务成功率、规划效率、规划失败原因、规划一致性和规划质量。其中，任务成功率用于衡量任务完成比例，规划效率用于衡量单位时间内完成的任务数量，失败来源统计用于分析失败是否由任务识别、子任务生成、任务分配或执行过程引起，规划一致性和规划质量则用于比较规划结果与专家标准答案之间的一致程度。

3.2 仿真结果与消融分析

表 1 不同方法的仿真结果对比

Tab.1 - Comparison of simulation results under different methods

方法	任务成功率	平均完成任务数	规划效率
本文方法	$(96 \pm 0.9)\%$	72.6	基线最优 +132%
基线最优方法	$(76 \pm 1.2)\%$	-	1.00
端到端大模型方法	<26%	-	较低
LiP-LLM	-	31.3	较低

在完整的 11 min 仿真过程中，系统共识别并处理 41 个任务，并进一步分解得到 155 个协作子任务。其中，火灾扑救、伤员救援、设备维护和泄漏处置四类任务分别出现 11、16、5 和 5 次，此外还动态生成 4 个探索类任务。任务级与子任务级执行结果表明，任务间及子任务间的时序约束均得到满足，说明所提方法能够在长时程、多任务并发和多机器人协同条件下保持规划结果的一致性与可执行性。

表 2 不同组件设置下的消融实验结果

Tab.2 - Ablation results under different component settings

模型/组件设置	子任务生成成功率	规划质量	平均完成任务数
完整方法	1.00	9.8	97.6
去除 RAG	-	5.4	47.3
去除 MS-p1	-	-	65.1
去除 MS-p2	-	-	69.7
去除人工校验	-	5.9	57.4

在高任务密度对比实验中，所提方法取得 $(96 \pm 0.9)\%$ 的任务成功率，基线方法中的最优结



图 5 典型任务执行过程

Fig.5 - Typical execution process in hardware experiments

果为 $(76 \pm 1.2)\%$ ，端到端大模型方法的成功率低于 26%。从完成任务数看，所提方法平均完成 72.6 个任务，高于 LiP-LLM 的 31.3 个任务；从规划效率看，相较于基线最优方法提升 132%。失效原因统计表明，所提方法在全部实验中仅发生 1 次失效，且出现在子任务生成阶段。

消融实验进一步分析 RAG、多阶段结构化推理和人工校验机制的作用。完整方法在子任务生成阶段取得 1.00 的成功率，规划质量为 9.8，平均完成任务数为 97.6。去除 RAG 后，规划质量降至 5.4，平均完成任务数降至 47.3；去除 MS-p1 和 MS-p2 后，平均完成任务数分别降至 65.1 和 69.7；去除人工校验后，规划质量降至 5.9，平均完成任务数降至 57.4。

3.3 实物验证

为进一步验证方法在真实机器人系统中的可部署性，实验搭建 $16\text{ m} \times 14\text{ m}$ 的小型工业园区应急处置场景，设置 4 处火情、3 名伤员、1 处储罐化学泄漏及若干应急资源。系统由 2 架无人机、4 台无人轮式车辆和 2 台四足机器人组成，并由 3 名操作员通过平板终端监督和交互。

完整实物实验持续 10 min。在该过程中，机器人集群共完成 8 个任务和 33 个子任务，并识别出 12 个环境要素。任务推理模块依据 LTL 约束生成任务顺序，优先实施伤员救援，其后处置较大火情，最后并行执行较小火情扑灭与储罐修复任务。云端将任务分配至 3 个作业群组，各群组平均承担 3 个任务；边缘侧任务分配模块以平均 0.5 s 完成子任务到机器人个体或团队的映射。实验过程中，任务推理、子任务生成和子任务分配模块分别触发 6 次、7 次和 10 次，表明所提方法能够依据事件影响范围进行局部更新，而非在每次扰动后执行完整重规划。

表 3 真实机器人系统中的实物实验结果

Tab.3 - Hardware experimental results on the real robotic system

指标	结果
任务成功率	100%
平均端到端规划时间	21.6 s
规划质量评分	9.7
规划一致性	95%
操作员工作负荷	7.5 降至 3.3，降幅 56%

上述结果说明，该方法在真实异构机器人平台上能够维持任务规划与执行过程的闭环运行，并降低操作员在复杂任务中的持续干预压力。

4 结论

本文面向动态开放未知场景下异构机器人集群任务规划问题，提出一种大模型与形式逻辑融合驱动的集群规划方法。该方法采用线性时序逻辑和任务自动机描述任务规范，并结合检索增强生成、多阶段大模型推理和滚动时域子任务分配，将自然语言任务目标转化为满足时序约束、能力约束和资源约束的子任务执行方案。

针对任务和资源持续变化的问题，本文进一步引入事件触发在线自适应机制，对新任务类型/实例、新资源类型/实例和机器人故障分别触发任务推理、子任务生成或局部分配更新，避免每次扰动都重新运行完整规划流程。同时，通过低负担人群协同机制，将人工参与集中在环境语义确认、任务推理校核、分配结果调整和高风险动作确认等关键环节。仿真与实物实验结果表明，所提方法在任

务成功率、规划一致性、动态事件处理和人工负担控制方面表现出较好的适用性。后续工作将进一步面向具身执行误差、间歇式通信条件和模块化扩展部署开展研究，以提升动态开放未知场景下长期任务执行的鲁棒性。

参考文献

- [1] T. Manzini, R. R. Murphy, E. Heim, C. Robinson, G. Zarrella, R. Gupta, Harnessing AI and robotics in humanitarian assistance and disaster response. *Sci. Robot.* 8, eadj2767 (2023).
- [2] X. Zhou, X. Wen, Z. Wang, Y. Gao, H. Li, Q. Wang, T. Yang, H. Lu, Y. Cao, C. Xu, F. Gao, Swarm of micro flying robots in the wild. *Sci. Robot.* 7, eabm5954 (2022).
- [3] R. Domínguez, C. Pérez-del-Pulgar, G. J. Paz-Delgado, F. Polisano, J. Babel, T. Germa, I. Dragomir, V. Ciarletti, A.-C. Berthet, L. C. Danter, F. Kirchner, Cooperative robotic exploration of a planetary skylight surface and lava cave. *Sci. Robot.* 10, eadj9699 (2025).
- [4] I. Kishor, U. Mamodiya, V. Patil, N. Naik, AI-Integrated autonomous robotics for solar panel cleaning and predictive maintenance using drone and ground-based systems. *Nature* 15, 32187 (2025).
- [5] B. R. van Manen, E. Fosch-Villaronga, M. Smits, Firefighting robots should be made responsibly. *Nat. Mach. Intell.* 7, 676–677 (2025).
- [6] D. Zhao, H. Luo, Y. Tu, C. Meng, T. L. Lam, Snail-inspired robotic swarms: a hybrid connector drives collective adaptation in unstructured outdoor environments. *Nat. Commun.* 15, 3647 (2024).
- [7] J. Tang, Z. Mao, H. Ma, Large-Scale Multirobot Coverage Path Planning on Grids With Path Deconfliction. *IEEE Trans. Robot.* 41, 3348–3367 (2025).
- [8] A. El Romeh, S. Mirjalili, Multi robot exploration using an advanced multi-objective salp swarm algorithm for efficient coverage and performance. *Sci. Rep.* 15, 26196 (2025).
- [9] H. Jeong, H. Lee, C. Kim, S. Shin, H. Jeong, H. Lee, C. Kim, S. Shin, A Survey of Robot Intelligence with Large Language Models. *Appl. Sci.* 14 (2024).
- [10] A. KA, U. Subramaniam, A systematic literature review on multi-robot task allocation. *ACM Comput. Surv.* 57, 1–28 (2024).
- [11] A.-I. Slean, B.-C. Gradinaru, O.-I. Gherman, M. Danubianu, L.-D. Milici, Opportunities and Challenges in Human-Swarm Interaction: Systematic Review and Research Implications. *Int. J. Adv. Comput. Sci. Appl. IJACSA* 14 (2023).
- [12] M. Ahn, others, “Do as i can, not as i say: Grounding language in robotic affordances” in *Proceedings of The Conference on Robot Learning (CORL)* (2023), pp. 287–381.
- [13] C. H. Song, B. M. Sadler, J. Wu, W.-L. Chao, C. Washington, Y. Su, “LLM-Planner: Few Shot Grounded Planning for Embodied Agents with Large Language Models” in *Proceedings of the 2023 IEEE/CVF International Conference on Computer Vision (ICCV)* (2023), pp. 2986–2997.
- [14] S. Wang, M. Han, Z. Jiao, Z. Zhang, Y. N. Wu, S.-C. Zhu, H. Liu, “Llm³: Large language model-based task and motion planning with motion failure reasoning” in *Proceedings of the 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)* (2024), pp. 12086–12092.
- [15] X. Zhang, H. Qin, F. Wang, Y. Dong, J. Li, “Lamma-p: Generalizable multi-agent long horizon task allocation and planning with lm-driven pddl planner” in *Proceedings of the 2025 IEEE International Conference on Robotics and Automation (ICRA)* (2025), pp. 10221 10221.
- [16] T. Silver, S. Dan, K. Srinivas, J. B. Tenenbaum, L. Kaelbling, M. Katz, “Generalized Planning in PDDL Domains with Pretrained Large Language Models” in *Proceedings of the AAAI Conference on Artificial Intelligence* (2024)vol. 38, pp. 20256–20264.
- [17] J. Ao, F. Wu, Y. Wu, A. Swiki, S. Haddadin, “LLM-as-BT-Planner: Leveraging LLMs for behavior tree generation in robot task planning” in *Proceedings of the 2025 IEEE International Conference on Robotics and Automation (ICRA)* (2025), pp. 1233–1239.
- [18] S. S. Kannan, others, “Smart-llm: Smart multi-agent robot task planning using large language models” in *Proceedings of the 2024 IEEE International Conference on Intelligent Robots and Systems (IROS)* (2024), pp. 12140–12147.
- [19] K. Liu, others, “COHERENT: Collaboration of Heterogeneous Multi-Robot System with Large Language Models” in *Proceedings of the 2025 IEEE International Conference on Robotics and Automation (ICRA)* (2025), pp. 10208–10214.
- [20] Z. Mandi, others, “Roco: Dialectic multi-robot collaboration with large language models” in *Proceedings of the 2024 IEEE International Conference on Robotics and Automation (ICRA)* (2024), pp. 286–299.